

Propuesta técnica — Plataforma de datos CaféNorte


Para: Dirección General y Dirección de TI, CaféNorte **De:** Tuxpas — AWS Advanced Partner **Fecha:** agosto 2026 · **Vigencia de la estimación:** 30 días

El problema, en una frase

Cada área reporta un número distinto porque cada sistema define "venta" de forma distinta. No es un problema de reportes: es que **no existe un lugar donde la definición viva una sola vez**. La prueba de concepto que acompaña esta propuesta ya lo demuestra con los datos que nos compartieron: sumar la columna de importes del POS tal cual sobreestima el ingreso **9.1%**, porque mezcla notas de crédito, complementos de pago, traslados de mercancía y hasta renglones de nómina. Y hay **tres productos que se venden por debajo de su costo en las 40 tiendas**, con una pérdida de **\$199,594 MXN en doce meses** que hoy nadie ve.

Lo que proponemos es un lugar único donde esas reglas estén escritas, probadas y sean auditables.

Arquitectura propuesta



Ingesta. Cada fuente entra a un bucket de S3 con su formato original: el POS y el ERP suben su export nocturno con un agente `aws s3 cp` autenticado con rol IAM temporal (sin llaves permanentes en las tiendas); Shopify y el tipo de cambio de Banxico los baja una función Lambda diaria. *Se descartó AWS Transfer Family SFTP: cuesta ~\$216/mes sólo por estar encendido, más que todo el resto de la plataforma junta.*

Procesamiento. Dos jobs de **AWS Glue 4.0 (PySpark)** aplican las capas `bronze` → `silver` → `gold`. Es literalmente el mismo código de la prueba de concepto: cambian la creación de la sesión y las rutas a `s3://`. **Step Functions** los orquesta con reintentos y avisa por SNS si algo falla. Los siete chequeos de calidad corren dentro del job y **abortan la corrida** en vez de publicar números malos — es la diferencia entre "el tablero está caído" y "el tablero miente", y la primera es mucho menos cara.

Consumo. **Athena** para que TI consulte con SQL estándar sobre los mismos datos que ve el tablero, y **QuickSight** para la dirección. Alertas por SNS cuando un SKU se queda en cero más de N días o cuando un producto cruza a margen negativo.

Lo que deliberadamente no proponemos: Redshift, EMR o Kinesis. Con el volumen de CaféNorte (~1.5 millones de renglones al año) cualquiera de los tres consume el presupuesto completo sin dar un solo número que Athena no dé. Si en tres años el volumen cambia de orden de magnitud, la migración a Redshift Serverless es incremental porque los datos ya están en Parquet particionado.

Costo mensual estimado

Región `us-east-1`, año 1, en USD. Supuestos: una corrida diaria, ~25 GB promedio de almacenamiento acumulado, 2 autores y 8 lectores de tablero.

Servicio	Supuesto	USD/mes
Amazon S3 (Standard + IA a 90 días)	25 GB + ~250k operaciones	1.80
AWS Glue ETL	2 DPU × 12 min diarios + 1 reproceso semanal	7.00
AWS Glue Data Catalog	< 1M objetos (capa gratuita)	0.00
AWS Lambda + EventBridge Scheduler	60 ejecuciones/mes	0.10
AWS Step Functions	30 ejecuciones × ~15 transiciones	0.02
Amazon Athena	~1,200 consultas, ~60 GB escaneados	0.30
Amazon QuickSight	2 autores (\$24 c/u) + 8 lectores (\$3 c/u)	72.00
Secrets Manager + KMS	2 secretos, 1 llave	1.90
Amazon CloudWatch	logs y alarmas	2.00
Total		≈ \$85

Queda 57% de holgura sobre los \$200 acordados. Triplicar el volumen mueve el total a ~\$100: el cómputo y el almacenamiento son la parte barata.

El costo escala con usuarios, no con datos. QuickSight es el 85% de la factura. Si mañana quieren que los 40 gerentes de tienda vean el tablero, son +\$120/mes y el presupuesto se aprieta. Vale la pena decidir desde ahora quién consume y cómo: un correo diario con el PDF del

tablero cuesta cero y puede cubrir al 80% de esa audiencia.

Plan de implementación

Fase	Duración	Entregable	Cómo sabemos que salió bien
0 • Definiciones	1 semana	Documento firmado de definiciones (qué es una venta, qué es un quiebre, qué entra al costo)	Finanzas y Operaciones firman el mismo documento
1 • Fundación	Semanas 1–3	Landing en S3, Glue bronze/silver, catálogo, Athena, las 4 preguntas, chequeos de calidad	TI consulta un número y coincide con el sistema origen
2 • Consumo	Semanas 4–6	QuickSight con 3 vistas (ventas, inventario, margen), alertas de quiebre y de margen negativo, automatización diaria	La dirección abre el tablero sin pedírselo a nadie
3 • Endurecimiento	Semanas 7–10	Carga incremental, histórico completo, pruebas de regresión, monitoreo de costos, runbook y capacitación	TI de CaféNorte corre un reproceso sin nosotros

La Fase 0 no es relleno. Es la fase que decide si el proyecto sirve. Mientras Finanzas y Operaciones no estén de acuerdo en si una nota de crédito resta del mes en que se emitió o del mes de la venta original, cualquier tablero que construyamos va a estar mal para alguno de los dos.

Riesgos

- El maestro de producto del ERP está incompleto.** Cinco SKUs con ventas no existen en la tabla de mapeo, incluido uno de los tres productos que pierden dinero. Lo resolvimos con una llave derivada del consecutivo numérico que comparten los tres sistemas, validada contra el mapeo oficial, pero **es una muleta**: si alguien da de alta un producto sin seguir la convención, se rompe. *Mitigación*: el pipeline se detiene en vez de callar; la solución de fondo es gobernar el catálogo en el ERP (Fase 3).
- Dependemos del catálogo de comprobantes del POS.** Si el proveedor del POS agrega un tipo nuevo sin avisar, el ingreso se rompe silenciosamente. *Mitigación*: contrato de datos con el proveedor y un chequeo que falla ante un tipo desconocido.
- El ERP entrega fotos, no movimientos.** Su propia metadata lo dice: "no incluye movimientos transaccionales". Sin entradas y salidas no se puede medir merma, ni reconstruir el inventario de una fecha pasada, ni calcular rotación con precisión contable. *Mitigación*: pedir la extracción de movimientos en la Fase 0; si no existe, el alcance de inventario se queda en disponibilidad y quiebres.
- Datos personales en Shopify.** Las órdenes traen nombre, correo, RFC y domicilio: son datos personales bajo la LFPDPPP. En la prueba de concepto los descartamos en la ingesta porque no hacen falta para ninguna de las cuatro preguntas. Si CRM los necesita, van a un bucket aparte con su propio cifrado, retención y control de acceso — no al lake analítico. *Decidir en Fase 0 si además hay requisito de residencia en México; la región `mx-central-1` existe, con ~15% de sobrecosto.*
- Una sola persona de TI del lado de CaféNorte.** Es el riesgo más común de que un proyecto así se apague seis meses después de entregado. *Mitigación*: runbook escrito y dos sesiones de capacitación en la Fase 3, con la corrida de un reproceso hecha por ustedes, no por nosotros.

Preguntas que necesitamos responder antes de firmar

- ¿Los montos del POS incluyen IVA?** Cambia todos los números de ingreso y margen. Hoy asumimos que sí (importe pagado por el cliente).
- ¿Una nota de crédito resta del mes en que se emite o del mes de la venta original?** Hoy resta del mes en que se emite.
- ¿El costo del ERP incluye flete y mermas, o es sólo precio de proveedor?** Si es lo segundo, el margen real es peor que el que reportamos.
- ¿Qué es un quiebre para Operaciones: cero piezas en sistema, o por debajo del punto de reorden?** Hoy usamos cero piezas, que es el caso más tarde posible de detectar.
- ¿Puede el ERP entregar movimientos de inventario y no sólo fotos diarias?**
- ¿Los cinco SKUs sin mapeo son error de captura o productos discontinuados?**
- ¿Cuántas personas van a consumir el tablero, y con qué frecuencia?** Es el 85% del costo mensual.
- ¿Basta con datos del día anterior a las 6 a.m., o hay decisiones que requieren información intradía?** La respuesta cambia la arquitectura, no sólo la configuración.
- ¿Cuántos años de histórico deben conservarse, y hay requisito de residencia de los datos en México?**

Anexo: la prueba de concepto —pipeline completo, 60 pruebas automatizadas y las cuatro respuestas verificadas contra un cálculo independiente— está en el repositorio que acompaña esta propuesta.